



KIRŞEHİR AHİ EVRAN ÜNİVERSİTESİ

BİLGİSAYAR MÜHENDİSLİĞİ

ARAŞTIRMA PROJESİ I

DEPOLANMIŞ HUBUBAT VE MAMULLERİNDE ZARARA NEDEN OLAN  
SEKONDER ZARARLILARIN YAPAY ZEKÂ VE GÖRÜNTÜ İŞLEME TEKNİKLERİ  
KULLANILARAK TEŞHİSİ

KADER SUTLU

DANIŞMAN:

Dr. Öğr. Üyesi MEHMET ALİ YALÇINKAYA

KIRŞEHİR - OCAK 2023

## **İçindekiler**

<b>DEPOLANMIŞ HUBUTAT VE MAMULLERİNDE ZARARA NEDEN OLAN SEKONDER ZARARLILARINDAN TRIBOLIUM CASTANEUM, TRIBOLIUM CONFUSUM VE ORYZAPHILUS SURINAMENSIS'İN YAPAY ZEKÂ VE GÖRÜNTÜ İŞLEME TEKNİKLERİ KULLANILARAK TEŞHİSİ.....</b>	<b>3</b>
<b>ÖZ.....</b>	<b>3</b>
<b>GİRİŞ .....</b>	<b>5</b>
<b>SEKONDER ZARARLILARINDAN TRIBOLIUM CASTANEUM, TRIBOLIUM CONFUSUM VE ORYZAPHILUS SURINAMENSIS.....</b>	<b>6</b>
<b>MATERYAL - YÖNTEMLER.....</b>	<b>10</b>
<b>Veri Seti.....</b>	<b>10</b>
<b>Veri Setinin Etiketlenmesi.....</b>	<b>11</b>
<b>Ön İşleme.....</b>	<b>13</b>
<b>Öznitelik Çıkarımı (Feature Extraction) .....</b>	<b>13</b>
<b>Yapay Zekâ .....</b>	<b>16</b>
<b>Derin Öğrenme.....</b>	<b>16</b>
<b>Derin Öğrenme Mimarisi.....</b>	<b>17</b>
<b>Yapay Sinir Ağları .....</b>	<b>19</b>
<b>Makine Öğrenmesi .....</b>	<b>19</b>
<b>LİTERATÜR ÇALIŞMALARI.....</b>	<b>20</b>
<b>KAYNAKÇA.....</b>	<b>22</b>

# **DEPOLANMIŞ HUBUTAT VE MAMULLERİNDE ZARARA NEDEN OLAN SEKONDER ZARARLILARINDAN TRIBOLIUM CASTANEUM, TRIBOLIUM CONFUSUM VE ORYZAPHILUS SURINAMENSIS'İN YAPAY ZEKÂ VE GÖRÜNTÜ İŞLEME TEKNİKLERİ KULLANILARAK TEŞHİSİ**

## **ÖZ**

Global düzeyde depolanmış ürün ve mamullerinde böcek kaynaklı zarar, teknolojik depolama teknikleri kullanılmadığı durumlarda %10-40 olarak kabul edilmektedir. Bu nedenle depolama süresince abiyotik ve biyotik stres faktörlerine karşı uygulanacak kontrol çalışmalarının yanı sıra depolama süresinde meydana gelebilecek her türlü ağırlık ve kalite kayıplarının engellenmesi bir zorunluluktur. Özellikle zarar görmüş “tane” de zarara neden olan sekonder zararlılarından Tribolium castaneum ve Tribolium confusum ve Oryzaphilus surinamensis ile bulaşıklık düzeyi ne olursa olsun savaşım bir zorunluluktur.

Bu kapsamda; zarar görmüş hububat tanesinde veya mamullerinde zarara neden olan üç türün depolanma aşamasında doğru teşhis edilmesi gereklidir. Diğer taraftan Tribolium castaneum ve Tribolium confusum aynı familyaya dahil yakın türler olup teşhisleri için konu hakkında uzman olmak gerekmekte ve depolama alanlarında böceğin görüntüsünü büyütmek için ekipmana ihtiyaç duyulmaktadır. Depolanmış hububatların ve mamullerinin rutin periyodik kontrollerinin uzmanlar tarafından yapılamaması veya depolarda büyütme ekipmanın olmaması zararlıların kontrolünde rutin kontrol çalışmaları için zaman kaybına ve uygulamada hatalara neden olabilmektedir. Teşhis sürecinin hızlandırılması ve doğru zamanda müdahale edilmesi için yapay zekâ ve görüntü işleme tekniklerinin kullanımı hem güncel konular hem de gelişmeye açık konulardır.

Yapay zekâ ve yapay zekânın bir alt tekniği de olan görüntü işleme teknikleriyle, elde edilen görüntüler üzerinde çeşitli işlemler uygulanarak, görüntüler yapay zekâ tekniklerinin uygulanması için hazır hale getirilmektedir. İşlenmiş görüntülerin, birbirleri arasındaki benzersiz özelliklerini önceden yapay zekâ ile tanıtılp sonradan eklenecek görüntülerin ayırt edilebilmesi sağlanmaktadır. Ayırt edilen görseller üzerinde, görüntü tanıma doğruluğunu iyileştirmek için ön işleme ve özellik geliştirme, görüntü işleme tekniklerinin uygulanması planlanmaktadır. Uzmanların çiplak gözle ya da mikroskopla ayırt etmekte zorlandığı bu

zararlıların yapay zekâ ve görüntü işleme teknikleri kullanılarak tür tespiti ve sınıflandırılmasının yapılması hedeflenmektedir.

**Anahtar Kelimeler:** Depolanmış hububat ve mamulleri, sekonder zararlilar, yapay zekâ, görüntü işleme, Python

## GİRİŞ

Depolanmış hububat ve hububattan imal edilen mamuller hem dünya hem de ülkemiz için sürdürülebilir gıda güvenliği için stratejik öneme sahiptir. Depolanmış hububat ve mamullerin depolama sırasında toplam ürün miktarının ve kalite özelliklerinin değişmeden hedeflenen veya belirlenen süre kadar depolanması global ve ülkesel düzeyde bir güvenlik sorunudur. Bu nedenle depolama sırasında hububatın özelliklerini yitirmeden depolanması kritik öneme sahiptir. Hububatların depolanması sürecince kayıplara neden olan abiyotik ve biyotik stres faktörlerinin şiddetine ve süresine bağlı olarak değişen düzeylerde önemli miktar ve kalite kayıpları yaşanabilmektedir. Bu duruma bağlı olarak global veya ülkesel düzeyde ve değişen seviyelerde gıda güvenliği sorunları oluşabilmektedir.

Depolanmış hububatlarda biyotik streslere bağlı olarak oluşan kayıpların %20 düzeyinde olduğu ve zararlilar (böcek vb organizmalar) kaynaklı kayıpların ise %10 düzeyde olduğu kabul edilmektedir (Emekçi ve ark., 2015; Güz ve ark., 2015). Bu zarar oranı bulaşma düzeyi veya depolama alanında bulunan zararlı yoğunluğuna bağlı olarak oluşabilecek kayıplar katlanarak daha da artabilmektedir. Zararlilar tarafından depolanmış ürün veya bitkisel mamullerde oluşabilecek nice ve kalite kayıplarına ek olarak zararliların ürünlere doğrudan veya dolaylı olarak bulaştırdıkları pislikleri, eğer zararlilar herhangi bir salgı salgılıyorsa, salgılamış oldukları ağ ya da benzeri maddeler ile vücut kalıntıları ürünün ekonomik değerini değiştiren düzeylerde olumsuz etkileyen öne çıkan önemli unsurlardır. Oluşabilen ağımızı yapılar işletmelerde bulunan mekanik aksamlarda ağ yapıları nedeniyle sorunlara yol açabilmektedir. Tüm bunlara ek olarak artan zararlı düzeyine bağlı olarak ürünlerde küflenme, kızışma ve kokuşma oluşabilmektedir. Bilerek veya bilmeyerek zararlilarla bulaşık gıda maddelerinin tüketilmesi, insan ve hayvan sağlığına değiştiren düzeylerde risk oluşturabilmektedir.

## **SEKONDER ZARARLILARINDAN TRIBOLIUM CASTANEUM, TRIBOLIUM CONFUSUM VE ORYZAPHILUS SURINAMENSIS**

Ana konukçusu hububat olan Coleoptera takımı Tenebrionidae familyasına dahil Tribolium castaneum (Herbst.) (Un biti) Tribolium confusum (Duval) (Kırma biti) ve Silvanidae familyasına dahil Oryzaphilus surinamensis L. (Testereli böcek) türleri kısmen veya tamamen zarar görmüş “tane”de zarara neden olmaktadır. Bu nedenle bu üç zararlının depolama alanlarında bulunmaları halinde en kısa sürede tespit edilerek hızla kontrol edilmesi bir zorunluluktur. Sayılan üç türün de bulaşıklığının depolanma alanlarında bir uzman tarafından kontrol edilmesi gerekmektedir. Tribolium castaneum ve Tribolium confusum yakın türler olup teşhisleri için konu hakkında uzman olmaya, böceğin morfolojisinin incelenmesi ve büyütülmesi için ekipmana ihtiyaç vardır. Depolanmış hububat da tavsiye edilen 20 günlük periyotlar olarak planlanmış rutin kontroller her zaman bir uzman tarafından yapılamayabilir. Depolanmış hububatların uzman tarafından kontrol edilememesi veya depolarda büyütme ekipmanın olmaması zararlının kontrol tespiti ve zararlının kontrolü için zaman kaybına ve uygulamada hatalara neden olabilmektedir.

Tribolium castaneum (Un biti); Gözün ön kısmındaki şakak çıkıştı göz hizasını geçmez. Antenlerindeki son üç parça boyut olarak eşit ve diğer parçalardan daha genişdir. Alt kısımdan her gözünün genişliği gözleri ayıran boşluğa kadar eşittir. Hiçbir sırtı sahip değildir. (Şekil 1) (Anonim, 2008).

Tribolium confusum (Kırma biti); Ergin parlak koyu kırmızı renkli, 3.5–4.0 mm boyda, yassı şekilde olup, baş ve göğüs sık noktalıdır. Kın kanatlarının üzeri boyuna ince çizgilidir. Gözün ön kısmındaki şakak çıkıştı göz hizasını geçer

Her iki türün yumurtası da beyaz renklidir. Larvalar olgunlaşlığında 5–7 mm boyunda, sarımsı krem rengi-akık kahve renkli bir hal alır Pupa önce beyaz sonra sarı renge dönüşür.

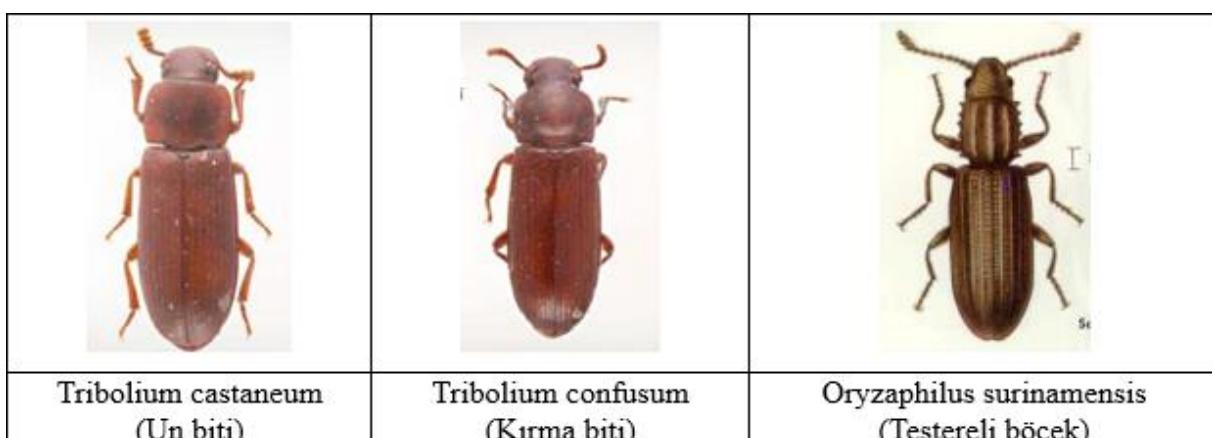
Anten parçaları, baştan son parçaya doğru aşamalı olarak artar. Göz genişliği gözleri ayıran boşluğun neredeyse 1/3’ü kadardır. Hemen gözün üzerinde yatay bir sırtı sahiptir. (Şekil 1) (Anonim, 2008).

Diger taraftan her iki türün ayrimi için uzmanların genellikle tercih ettiği yöntem olarak “zararlının büyütme yapılarak göz ile teşhis” kullanılmaktadır. Antenler Tribolium spp. ayırmadaki en önemli araçlardır. Tribolium castaneum’da son 3 parça boyut olarak eşit ve diğer parçalardan daha genişdir. Tribolium confusum (Kırma biti)’un anten parçaları, baştan son parçaya doğru aşamalı olarak artar. Alt kısımdan, T. castaneum’un her gözünün genişliği

gözleri ayıran boşluğa kadar eşit iken, *T. confusum*'un göz genişliği gözleri ayıran boşluğun neredeyse 1/3'ü kadardır. *T. castaneum* hiçbir sırtı sahip değilken, *T. confusum* gözün üzerindeki başın üzerinde yatay bir sırtı sahiptir.

*Oryzaphilus surinamensis* (Testereli böcek): İnce, uzun, yassı şekilli, kırmızıdan koyu kahveye kadar değişen renkte bir böcektir. Uzunluğu 2.5–3 mm'dir. Pronotumun her iki yanında 6'shar adet testere dişi şeklinde çıkıntı tür için tipiktir. . Yumurta beyaz renkli, ince ve uzun şekillidir. Larva silindirik şekele, beyaz renkli ve 3 mm uzunluktadır. Pupa krem renkli 3–3.5 mm boydadır. Erginler 8–10 ay yaşarlar. Bir dişi ortalama 170 adet yumurta bırakır. . Larva 5 gömlek değiştirerek pupa olur.Uygun koşullarda gelişme süresi 5-6 haftadır. Yılda 5–6 döl verir. (Şekil 1) (Anonim, 2008).

Bu zararlı diğer iki zararlıdan şekele, davranışsal ve biyolojik olarak çok farklı olup, hazırlanan yapay zekâ ve görüntü işleme projesinin doğru teşhis yapabilme kabiliyeti ve düzeyi bu zararlı ile test edilmek amacı ile projeye dahil edilmiştir.



Şekil 1: *Tribolium castaneum* (Un biti) *Tribolium confusum* (Kırma biti) ve *Oryzaphilus surinamensis* (Testereli böcek) türlerinin ergin dönemleri

Teorik Üreme Emsalinin (Böcek Üreme Gücü) hesaplanmasında “ $m= n (axbxy)^x$ ” formülü kullanılmaktadır. Böceğin üreme gücünün hesaplanması ile konuya şu şekilde bir örnek verilebilir (Kansu, 2016).

*Tribolium castaneum* (Un biti); zararlısının bir dişi ömrü süresince ortalama bıraktığı yumurta sayısı 350 olsun ve cinsiyet oranı 1/1 olsun. Zararlı yılda beş döl verdiği kabul edilse bir erkek bir dişiden popülasyondan 3. 4. ve 5. dölu sonunda kaç birey oluşur?” sorusunun cevabı şeklärindedir.

m=?	1. döl sonucu oluşan zararlı sayısı= 350
n= bir erkek bir dışiden popülasyondan (1+1)=2	2. döl sonucu oluşan zararlı sayısı= 61.250
a=300 adet	3. döl sonucu oluşan zararlı sayısı= 10.718.750
b= cinsiyet oranı 1/1 ise cinsiyet faktörü 1 dişi/2 toplam birey (1dişi+1 erkek)=0,5	4. döl sonucu oluşan zararlı sayısı= 187.5781.250
y= 1 yumurta 1 birey	5 döl sonucu oluşan zararlı sayısı= 328.261.718.750
x=3., 4. ve 5 döl hesaplanacak yani üst 2, 4 ve 5 olacak	

“Eğer 1.000 tane 40 gram gelirse 5. döle kadar zarar gören tane sayısını ve zarar gören miktarı kg olarak hesaplayınız?” sorusunun cevabı şeklindedir.

Zarar gören tane sayısı (Neredeyse depolama şartlarında 1 yıl sonunda oluşan popülasyon)

1. döl sonucu oluşan toplam zararlı sayısı= 350 adet böcek
2. döl sonucu oluşan toplam zararlı sayısı=  $61.250 + 350 = 61.600$  adet böcek
3. döl sonucu oluşan toplam zararlı sayısı=  $10.718.750 + 80.400 = 10.718.750$  adet böcek
4. döl sonucu oluşan toplam zararlı sayısı=  $187.5781.250 + 9.060.00 = 1.886.500.000$  adet böcek
5. döl sonucu oluşan toplam zararlı sayısı=  $328.261.718.750 + 1.359.000.000 = 328.261.718.750$  adet böcek olarak hesaplanmıştır.

Zarar gören miktar (kg) (Neredeyse depolama şartlarında 1 yıl sonunda oluşan ürün miktarı (kg))

1. döl sonucu oluşan 350 adet böcek 14 gr ürünü zarar yapar.
2. döl sonucu oluşan 61.250 adet böcek 2 kg 450 gr ürünü zarar yapar.
3. döl sonucu oluşan 10.718.750 adet böcek 428 kg 750 gr ürünü zarar yapar.
4. döl sonucu oluşan 187.5781.250 adet böcek 75 ton 31 kg 250 gr ürünü zarar yapar.
5. döl sonucu oluşan 328.261.718.750 adet böcek 13.130 ton 468 kg 750 gr ürünü zarar yapar.

Yukarıda yapılan hesaplamalar sadece 1 erkek ve 1 dışiden oluşan başlangıç popülasyonunun 5. döl sonucu oluşturduğu popülasyonu ve zarar miktarı olup gıda

güvenliğine tehdit edecek yüzeydedir. Artan ortam sıcaklığı ile bu zarar katlanarak artacaktır. Bu nedenle depolanmış ürünlerin bulunduğu alanda zararlı bulaşıklığın tespitinin en kısa sürede ve mücadele öncelikli bir konu olarak zorunlu bir iştir. Yukarıda sayılan Coleoptera'ya dahil türler az ya da çok zarar görmüş tane de (sağlam tanede küflenme, kızışma ve kokusma oluşabilmekte bu nedenle sağlam tanede zarar oluşabilmektedir) zarar oluşturabildiği için tür tespitinin doğru yapılması önemli ve üzerinde durulması gereken bir konudur. Depolanmış ürün konusunda uzman olmayan veya tecrübesiz personeller, oluşan zarara zamanında müdahale edemeyeceği için zarar katlanarak artabilecektir.

Konunun çözümümde günümüz teknolojisini kullanarak yapay zekâ ve görüntü işleme tekniklerinin kullanımı problemin belirlenmesi ve zamanında müdahale için farklı fırsatlar sağlayabilmektedir.

Yapay zekâ en kısa açıklama ile “insan beyninin ve düşünme sisteminin kopya edilmesi” olarak tanımlanabilir. Tanımı biraz daha sade bir şekilde yapmak gerekirse; “bir bilgisayar programını insan gibi düşünebilecek hâle getirme” cümlesi kullanılabilir. Yapay zekâ sistemi, her başarılı veri işleme turu sonrasında daha akıllı hale gelmektedir, Bunun nedeni her etkileşim, sistemin çözümleri test etmesine, ölçmesine ve başarmak üzere ayarlandığı görevde uzmanlık geliştirmesine imkân tanımaktadır. Yapay zekâ sistemleri, bir insanın benzer işleri yapabileceği orandan çok daha hızlı bir şekilde tamamlayabileceğinden insanlardan çok daha hızlı uzman hale gelebilir. Bu durum yapay zekâyı akıllı karar verme gerektiren herhangi bir süreç için inanılmaz derecede etkili hale getirmektedir. Sonuç olarak tüm bunlar, yapay zekâyı inanılmaz derecede güçlü ve son derece değerli bir teknoloji yapmaktadır.

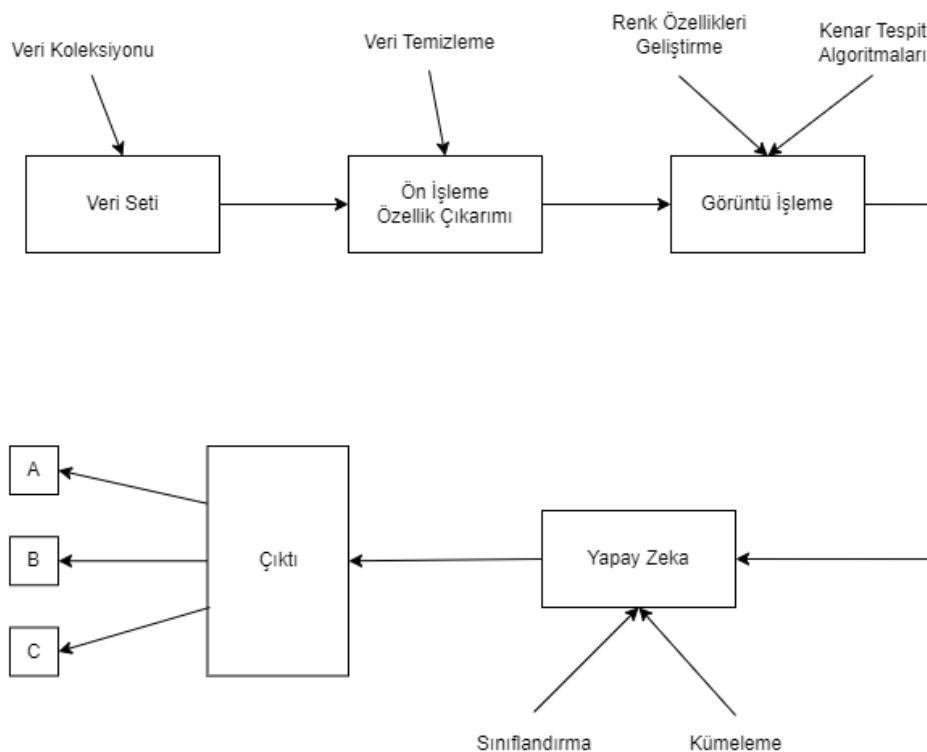
Gelişen teknolojiyle birlikte yapay zekanın çalışma alanı da genişlemiştir. Yapay zekâ sadece bununla sınırlı kalmayıp kendi kendine öğrenebilen ve kendini geliştiren sistemler, insan zekasından bağımsız gelişebilecek bir kavrama doğru ilerlemektedir.

Yapay zekânın alt dallarından biri olan derin öğrenme, oluşturulan veri setlerinden sonuçlar üreterek tahminde bulunan birden çok katmandan meydana gelen makine öğrenme yöntemidir.

## MATERİYAL - YÖNTEMLER

Materyal ve yöntemler bu bölümde ele alınmıştır. Veri seti, yazılım, donanım ve değerlendirme ölçümleri açısından yapılan deneyleri açıklar. Yapılan çalışmalar temelde yazılım ve donanım olarak iki başlık altında toplanır. Donanım, sağlıklı görüntü elde etmek ve bu görüntülerin işlenmesi için yararlanılan çevre koşullarını tanımlarken yazılım, görüntülerin çeşitli algoritmalarla işlenmesi ve kullanıcıya anlamlı çıktı vermesini tanımlamaktadır. Donanımda oluşan sorunlar yazılımda da sorunlara neden olabilmektedir.

Proje boyunca izlenecek adımlar Şekil-2'deki gibidir.



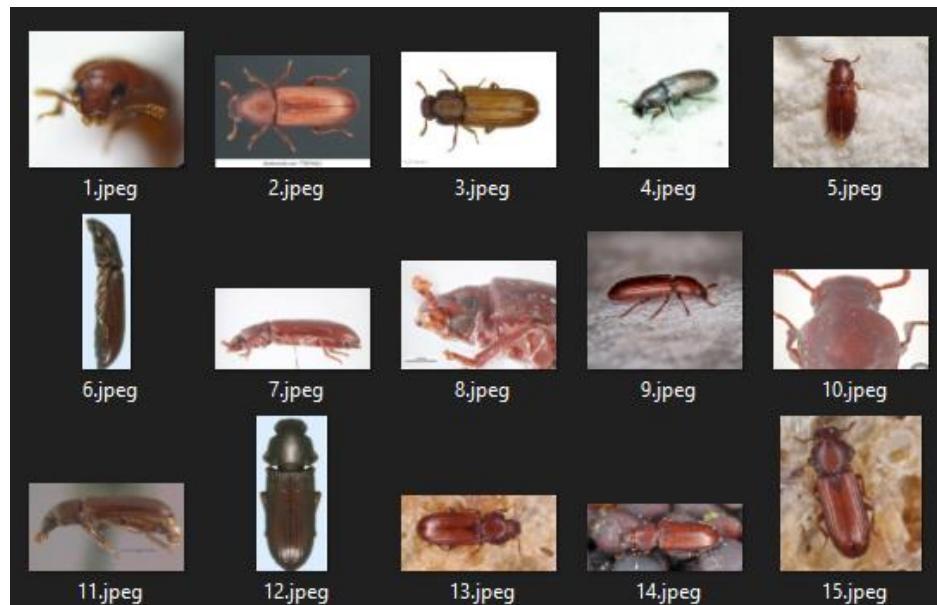
Şekil 2: Proje geliştirilirken izlenecek adımlar

### Veri Seti

Bu makalede, sekonder zararlıların sınıflandırmasında kullanılacak veriler hakkında bilgi yer almaktadır. Geliştirilecek modelin doğruluğu tamamen toplanan verilere bağlıdır. Bu yüzden sağlam ve doğru model oluşturmak için “daha fazla veri, daha güçlü model” felsefesi benimsenmiştir [1]. Önerilen modelin özgünlüğü ve veri miktarını yüksek tutmak için Kırşehir Ahi Evran Üniversitesi Ziraat Fakültesi Bitki Koruma bölümünün yardımıyla veri

seti oluşturulmuştur. Veri setindeki görüntüler her böcek için en az 200 adet olacak şekilde belirlenmiştir.

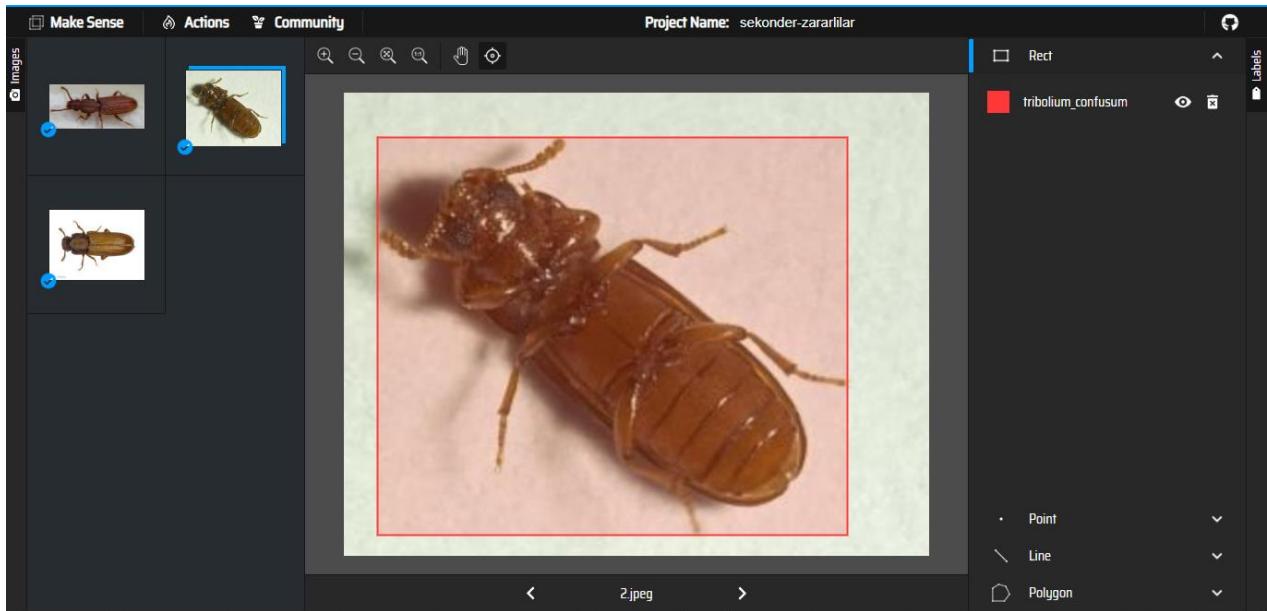
İlk adımda toplanan görüntülerin daha rahat etiketlenebilmesi için Şekil-3'tteki gibi isimleri değiştirilmiştir.



Şekil 3 : Görüntü İsimlendirme

### Veri Setinin Etiketlenmesi

Oluşturulan veri setinde bulunan resimlerdeki böcekler makesense.ai sitesi kullanılarak etiketlendirildi. Etiketleme işlemi rectangular bounding box (dikdörtgen kutu sınırlama) tekniği kullanıldı. Çizilen sınırlardaki böceklere isimleri verilerek sınıflandırılması yapıldı. Sınıf isimleri “oryzaphilus\_surinamensis”, “tribolium\_castaneum”, “tribolium\_confusum” şeklinde dir. Etiketleme örneklerinden biri Şekil-3’té gösterilmiştir.



Şekil 4: Veri setindeki etiketli resimlere bir örnek

Etiketleme işlemi tamamlandıktan sonra görüntüler YOLO formatında Şekil-4'teki gibi kaydedilmiştir.



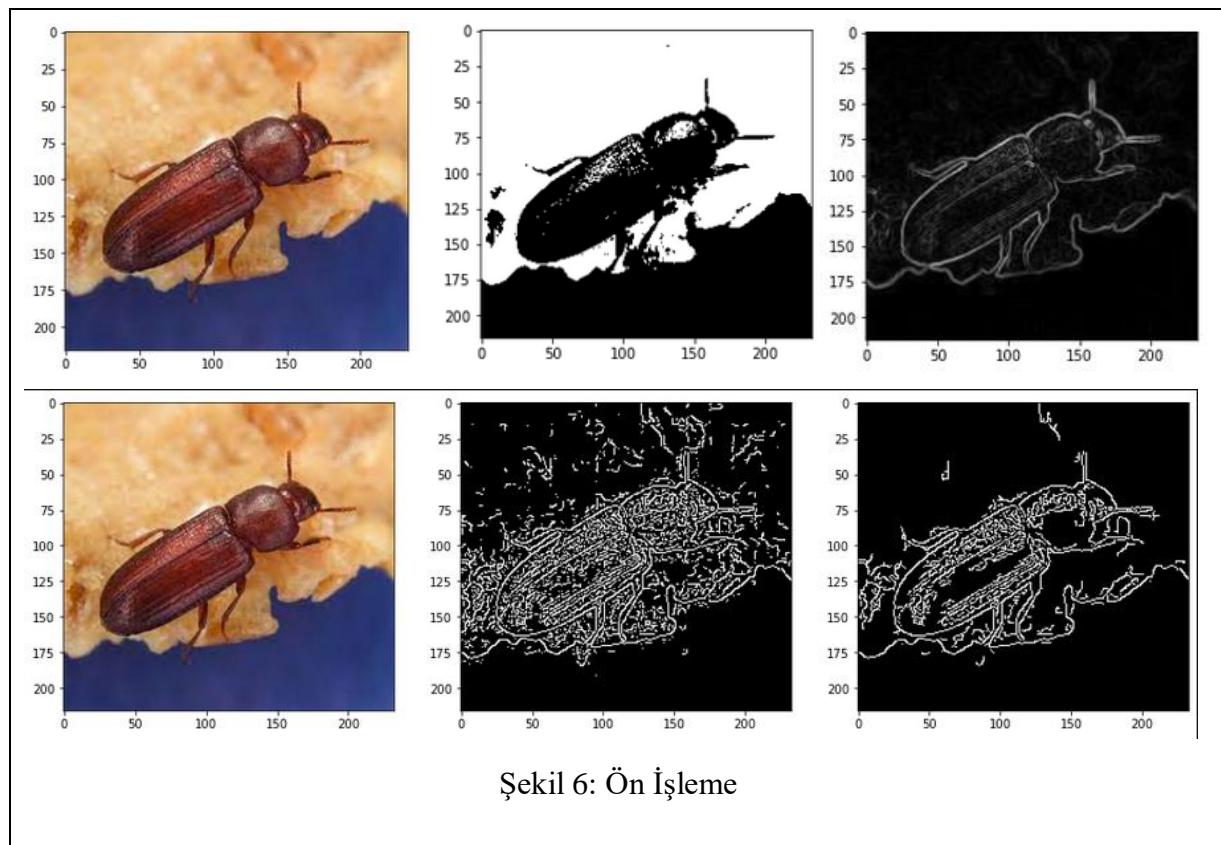
1.txt - Not Defteri

Dosya Düzen Biçim Görünüm Yardım  
0 0.464602 0.520171 0.914454 0.946464

Şekil 5: Etiketlenmiş Verinin YOLO formatında koordinatları

## Ön İşleme

Görüntülerin boyutu ve rengi, görüntülerdeki parazitler gibi parametreler model eğitilmesinde önemli bir yere sahiptir. Bu yüzden oluşturulan veri setindeki görüntüler üzerinde çeşitli işlemler yapılarak görüntüler modellenmeye hazır hale getirilmektedir. Veriler üzerinde yapılan bazı işlemler Şekil-5'te gösterildiği gibidir.



Şekil 6: Ön İşleme

## Öznitelik Çıkarmı (Feature Extraction)

Veri setindeki görüntülerden elde edilen öznitelikler, görüntü işleme barındıran yazılım uygulamalarında oldukça önemli bir yere sahiptir [2]. Öznitelikler elde edilmeden önce görüntü üzerinde renk uzayı dönüşümleri, boyutlandırma, filtreleme gibi çeşitli görüntü ön işleme teknikleri uygulanmaktadır. Bu işlemlerden sonra görüntülerin tespiti ve sınıflandırılması, görüntüler hakkında bilgiler verebilecek özniteliklerin elde edilmesi için öznitelik çıkarma teknikleri veya algoritmaları uygulanır [3,4]. Öznitelik çıkarma teknikleri, medikal görüntü işleme uygulamalarında faydalıdır. Öznitelikler, görüntülerin istenilen özellikte davranışlarını tanımlayıp kullanılacak olan depolama alanını, direkt görüntü

isleyerek algoritmanın kaybedeceği zamanı en aza düşürücü etkiye sahiptir [2]. Özellikle çıkarmanın temel amacı, orijinal verilerden elde edilen en uygun bilgiyi daha düşük boyutlu bir uzayda temsil etmektir [2]. Bir algoritmanın girdi verileri eşleştirme yapamayacak kadar büyük olduğunda öznitelik çıkarımı kullanılmaktadır. Girdi verileri özniteliklerin [1,2]. Yaygın olarak kullanılan öznitelik çıkarma yöntemleri arasında şablon eşleştirme, deformable şablonlar, kontur profilleri, spline eğri yaklaşımı ve gabor sayılabilir.

### **Veri Setinin Modellenmesi**

Bu çalışmadaki veri seti, eğitim seti, doğrulama seti ve test seti olarak 3 gruba ayrılmıştır. Eğitim seti geliştirilirken kullanılan ortam değişkenleri Tablo-1'de gösterildiği gibidir.

RAM	8 GB
CPU	Intel(R) Core(TM) i5-8265U CPU @ 1.60GHz - 1.80 GHz
Geliştirme Ortamı	Google Colab
Programlama Dili	Python
Model	YOLOv5

Tablo 1: Ortam Değişkenleri

### **Google Colab**

Collab, Google tarafından geliştirilen bir platformdur. Bu platform, aynı anda birden fazla kullanıcının ortak olarak çalışabildiği bir çalışma alanı sağlamaktadır. Collab, çeşitli tipteki dosyaları paylaşmayı, bu dosyalar üzerinde ortak olarak çalışmayı ve bu çalışmaları takip etmeyi mümkün kılar. Örneğin, bir grup proje üyesi Collab kullanarak, proje ile ilgili tasarımları paylaşabilir ve bu tasarımlar üzerinde ortak olarak çalışabilir. Aynı şekilde, bir ekip Collab kullanarak, çalışmalarını takip edebilir ve bu çalışmaların nerede olduğunu ve ne zaman tamamlanacağını görebilir. Collab, web tabanlı bir platformdur ve internet bağlantısı olan herhangi bir cihazdan erişilebilir. Bu proje için Collab çalışma ortamı seçilerek projenin saklı tutulması, istenilen zaman diliminde istenilen cihazdan kolayca erişim sağlanabilmesi amaçlanmıştır.

## **Python**

Popüleritesi gün geçtikçe artmakta olan Python güçlü programlama dillerinden biri olması, kolay söz dizimi ile C++ veya Java'ya genişletilebilir bir dil işleyicidir. Programlama Topluluğu Endeksi (TIOBE)'e- ayda bir kez güncellenen ve programlama dillerinin popülerliğini gösteren endeks - göre, Python en çok kullanılan programlama dili ilan edilmiştir [3]. Python, masaüstü yazılımları, web programlama uygulamaları, veritabanı uygulamaları, bilimsel analizler ve hesaplamaları, paralel programlama, sayısal görüntü ve işaret işleme uygulamaları, ağ programlama vb. gibi birçok uygulamanın geliştirilmesinde kullanılmaktadır [4].

## **Python Temel Paketleri**

Python programlama dili, kullanıcıya birçok çeşitli modül ve kütüphaneyi gömülü olarak sağlamaktadır. Bu modül ve kütüphaneler ile modüler hesaplama, veritabanı yönetimi, web sunucusu işlevleri vb. işlemler gibi birçok işlev gerçekleştirilmektedir. Bu çalışmada böcek türlerinin otomatik tespiti ve sınıflandırılmasına odaklandığı için, NumPy, Matplotlib, OpenCV paketleri açıklanmıştır.

## **NumPy**

NumPy, artık kullanılmayan, Numeric ve Numarray modüllerinden türemektedir. NumPy, bilimsel hesaplamalar için sıkılıkla kullanılan bir Python kütüphanesidir. Numpy, kompleks matematiksel fonksiyonlar, rastgele sayı üretme, lineer cebir gibi işlevleri barındırmaktadır. Bunun yanı sıra hızlı ve çok yönlü vektörleştirme, indeksleme, C/C++ ve Fortran kodlarını entegre etmek için araçlar ve kullanışlı doğrusallık sağlamaktadır [5,6]. Bu çalışmada ağırlıklı olarak matrisler kullanılacağı için NumPy'ın matris işleme yeteneklerinden faydalanaacaktır.

## **Matplotlib**

Matplotlib, bir 2B çizim kütüphanesidir. Matplotlib, Python'ın matematiksel bir kütüphanesi olan Numpy için kullanılan çizim kütüphanesidir [7]. Grafik kullanıcı arayüzü (GUI) kullanarak çizimleri web sitesi, masaüstü gibi uygulamalara yerleştirmek için yada nesne yönelimli API sağlamak içinde kullanılmaktadır. Matplotlib ile grafikler, resimler, histogramlar çizdirilebilir. Matplotlib grafikler üzerinde başlık, eksen isimleri, grafik işaretleme gibi özellikleri içermektedir [8].

## **OpenCV**

OpenCV, akademik kurumlar, ticari kuruluşlar, devlet kurumları gibi geniş kullanıcı ağına sahip bir kütüphanedir [9]. Python, Java, C, C++ gibi çeşitli diller için geliştirilmiş açık kod kaynak (open-source) bir kütüphanedir. OpenCv GUI özelliklerini yönetme, görüntü işleme, nesne algılama, video analizi, camera kalibrasyonu vb. birçok alanda kullanılmaktadır. Aynı zamanda içerisinde 2000'den fazla görüntü işleme algoritması bulunduran bilgisayarlı görme ve makine öğrenimi yazılım kütüphanesidir [9]. Bu çalışmada görüntü ön işleme aşamasında OpenCV kullanılmıştır.

## **Yapay Zekâ**

Yapay zekâ, bir işin insan tarafından yapıldığında insanı zeki olarak adlandırılan davranışların makineler tarafından yapılmasıdır [10]. Bir sistemin zeki olarak nitelendirilebilmesi için öğrenme yeteneğine sahip olması gereklidir [11]. İnsan öğrenmesinde deneyimler ile yapay zekâ ise veriler ile öğrenme sağlanır [11].

Gelişen teknolojiyle birlikte yapay zekanın çalışma alanı da genişlemiştir. Yapay zekâ sadece bununla sınırlı kalmayıp kendi kendine öğrenebilen ve kendini geliştiren sistemler, insan zekasından bağımsız gelebilecek bir kavrama doğru ilerlemektedir.

Yapay zekânın alt dallarından olan derin öğrenme ve makine öğrenmesi, oluşturulan veri setlerinden sonuçlar üreterek tahminde bulunan birden çok katmandan meydana gelen öğrenme yöntemleridir.

## **Derin Öğrenme**

Derin öğrenme, bilgisayarların eğitilen modelleri deneyimleyerek bu deneyimlerden ders almasını ve dünyayı kavramalar açısından anlamasını sağlayan bir makine öğrenmesi yöntemidir [12]. Literatürde derin öğrenme kullanılarak birçok uygulama geliştirilmiştir. Doğal dil işleme, görüntü ve video işleme, biyomedikal sinyal ve görüntü işleme, nesne tanıma, robotik, gibi çeşitli konularda derin öğrenme uygulamaları geliştirilmektedir [13]. Derin öğrenme temel olarak veri setlerinden öğrenmeye dayanmaktadır. Bu çalışmada ele alınan yapay zekâ ve görüntü işleme teknikleri kullanılarak tür tespiti yapma ile ilgili akademik çalışmalar son yıllarda popülerlik kazanmıştır.

## **Derin Öğrenme Mimarisi**

Derin öğrenme kavramı ilk olarak insan beynindeki bir nöronun bilgisayara benzetilmesiyle ortaya çıkmıştır. Donald Hebb'in sinir hücresindeki sinir ağlarının yapısının incelemesiyle ilk çalışmalara başlanmıştır. Bu incelemeyle birlikte yapay sinir ağları ortaya çıkmıştır [13]. Yapay sinir ağları yönteminin kullanılabilmesi için veri setinde öznitelik çıkarma işlemini uygulamak gerekmektedir. Öznitelik çıkarımında elde edilen öznitelikler arasından en iyileri tespit edilmelidir [14]. Derin öğrenme özellikle sınıflandırma, tanıma ve tespit için kullanılmaktadır [15]. Son zamanlarda birçok alanda derin öğrenme algoritmalarının kullanılması ve yüksek başarımla elde edilmesi bu konuya eğilimi arttırmıştır.

Derin öğrenme mimarisinde modelin eğitimi esnasında denetimli öğrenme, denetimsiz öğrenme, takviyeli öğrenme olarak birkaç farklı öğrenme stratejisi bulunmaktadır. Denetimli öğrenmede modelin girdisinden elde edilecek sonucun ne olduğuyla ilgilenir. Aynı veriler tekrar tekrar eğitilerek girdi buna göre düzenlenir. Denetimsiz öğrenmede, modelin girdi verisinden elde edilecek sonuç bilgisi verilmeden verinin çıkışta yakın bir kümeye ait değer alıp bir kümenin üyesi olmasını sağlar. Takviyeli öğrenme ise denetimsiz öğrenmedeki gibi sonuçla ilgilenmeden çıkışa doğru ya da yanlış bilgisi verilir. Doğru ise 1 yanlış ise 0 değeri atanarak modelin eğitimi gerçekleştirilir [15].

Derin öğrenme, çok katmanlı bir yapıya sahiptir ve her katmanda ayrı işlemler yaparak elde edilen çıktıları bir sonraki katmana iletir. Derin öğrenme algoritmalarına göre veriler Şekil 6'da gösterildiği sırayla; giriş, evrişimsel, aktivasyon, havuzlama, ezberleme, tam bağlantı ve sınıflandırma katmanlarından geçirilerek sonuçlar üretilmektedir. Derin öğrenme katmanları sırasıyla şu işlemleri yapmaktadır:

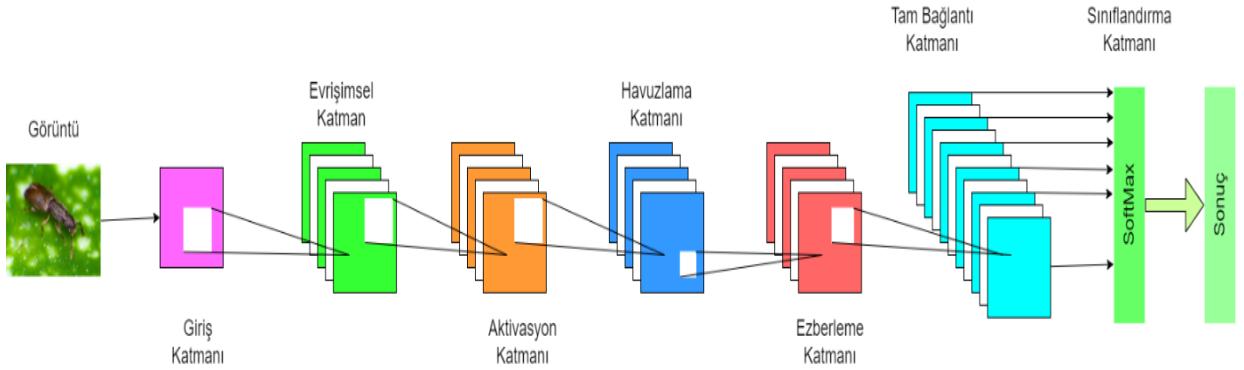
**Giriş Katmanı:** Görüntülerin RGB'den, griye dönüştürülmesi ve standart ebatlara getirilmesi işlemi yapılır [14].

**Evrişimsel Katmanı:** Bir önceki katmandan gelen verilere filtreleme işlemi uygulanarak öznitelik çıkarama işlemi yapılır [14].

**Aktivasyon Katmanı:** Evrişimsel katmanından gelen değerlerin ReLU aktivasyon fonksiyonu ile düzenlenmesi sağlanır [14].

**Havuzlama Katmanı:** Bir önceki katmandan gelen verileri daha küçük boyutlara indirger [14].

Tam Bağlantı Katmanı: Tüm verileri matrise dönüştürerek sınıflandırma için Yapay sinir ağlarını kullanır [14].



Şekil 7: Derin Öğrenme Katmanları [10]

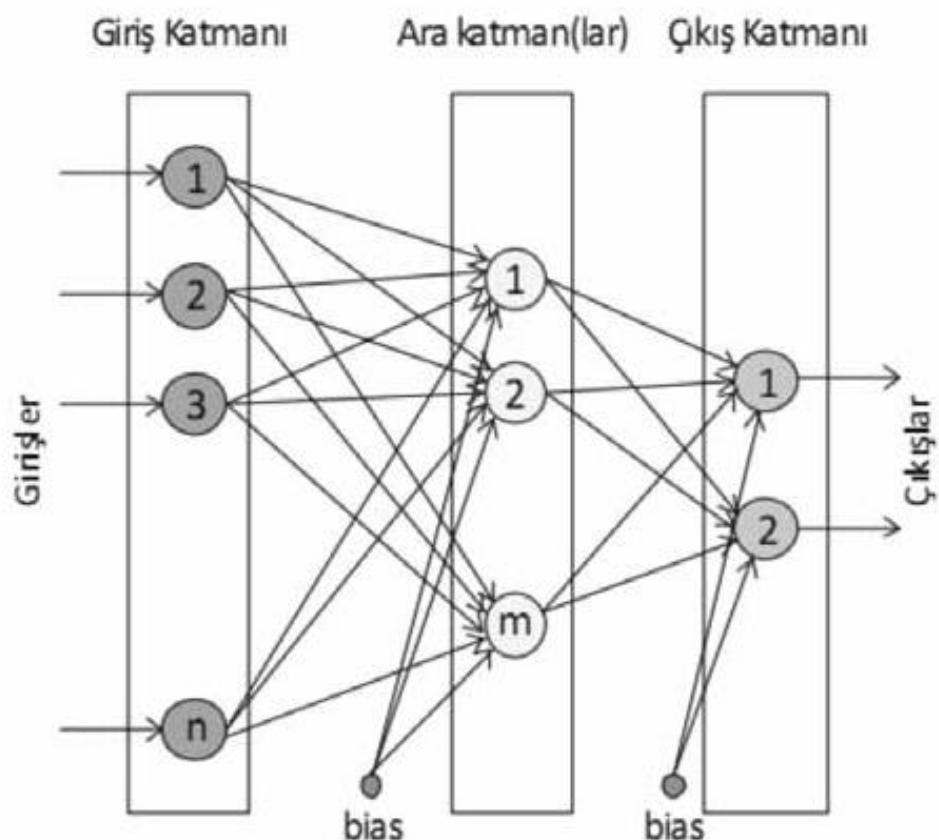
Şekil-6'daki katmanlar, farklı derin öğrenme algoritmalarında farklı sayıarda ve kombinasyonlarda eklenecek AlexNET, VGG16, GoogleNet, YoloV5 gibi farklı derin öğrenme algoritmalarını oluşturabilmektedir [14]. Bu projede YOLOv5 algoritması kullanılmıştır.

## YOLOv5

YOLOv5 (You Only Look Once version 5) bir görüntü tanıma algoritmasıdır ve bu algoritma kullanılarak görüntülerde nesnelerin konumları ve türleri tespit edilebilir. YOLOv5'i kullanarak böceklerin tespiti için, öncelikle böcek türlerine ait veri kümesine oluşturuldu. Bu veri kümesi, böceklerin resimleri ve bu resimlerin hangi tür olduğu bilgisini içermektedir. Bu veri kümesini oluşturmak için böceklerin farklı açılardan görüntülerini ve bu görüntülerin etiketlenmiş halleri gerekmektedir. Veri kümesi oluşturulduktan sonra, YOLOv5 algoritması kullanılarak modelin eğitimi gerçekleştirilmektedir. YOLOv5 modelini eğitirken, veri kümesinin bir bölümü eğitim verisi, geri kalanı da test verisi olarak kullanılmaktadır. Bu sayede, eğitim verisinde öğrenilen bilgilerin test verisinde nasıl uygulandığı görülebilir ve modelin başarımı değerlendirilmektedir. Modelin başarımı değerlendirildikten sonra, gerekirse model iyileştirmeye yönelik değişiklikler yapılarak tekrar eğitilebilir.

## Yapay Sinir Ağları

Yapay Sinir Ağları (Artificial Neural Networks) insan beyninden esinlenerek geliştirilmiş, ağırlıklı bağlantılar aracılığı ile birbirine bağlanan bilgi işleme yapılarıdır. En önemli özelliği, deneyimlerden (tecrübe) yararlanarak öğrenebilmesidir. Yapay sinir ağları, insan beyninin özelliklerinden olan öğrenme yolu ile yeni bilgiler türetilme, yeni bilgiler oluşturabilme ve keşfedebilme gibi yetenekleri herhangi bir yardım almadan otomatik olarak gerçekleştirmek amacıyla geliştirilmişlerdir. Yapay sinir ağları, öğrenmenin yanı sıra bilgiler arasında ilişkiler oluşturma yeteneğine de sahiptir. Bir yapay sinir ağının temel olarak girdilerden, ağırlıklardan, toplama işlevinden ve çıktıdan oluşur (Şekil 7).



Şekil 8: Yapay sinir ağları modeli[13]

## Makine Öğrenmesi

Makine öğrenmesi, insanların öğrenme yeteneğini taklit etmek için veri ve algoritmaların kullanımına dayalı, ögrendikçe doğruluk oranının arttığı bir yapay zekâ alt dalıdır [15]. İstatistiksel yöntemlerle algoritma, sınıflandırma veya tahmin yapılması gereken projelerde temel bilgileri ortaya çıkarmak için sıkılıkla kullanılır. [15]. Bir e-ticaret sitesinden ürün

alındığında o ürünle alınan diğer ürünlerin gösterilmesi, akıllı bilekliklerin kişiye özel aktiviteler çıkarması, kameralarda bulunan yüz tanıma sistemleri, para akışına göre yasal olmayan işlemlerin tespiti gibi birçok alanda görülmektedir.

## LİTERATÜR ÇALIŞMALARI

Yapay zekâ ve görüntü işleme teknikleri kullanılarak birçok sınıflandırma çalışmaları yapılmıştır. Böcek türleri sınıflandırma, bitki türleri sınıflandırma, hastalık sınıflandırma bu çalışmaların başında gelmektedir. 2015'ten önce, böcek türlerini ayırt etmek için raporlanan tüm çalışmalar dijital görüntü özelliğinden el ile tanımlaya dayanıyordu. Daha sonra, derin öğrenme tekniğinin gelişmesi nedeniyle otomatik tanıma olan derin öğrenmeye dayalı yöntemler, tüm araştırmacıların ilgisini çekmeye başladı.[16]

Andres Hernandez Serna ve Luz Fernanda Jimenez Segura, Avrupa ve Güney Amerika'daki balık, bitki ve kelebek türlerini sınıflandırmak için fotografik görüntüleri kullanan yapay sinir ağları kullanılmıştır.

Farklı tarla bitkileri için 2020 yılında Wang [17] ve Xie [18] veri seti kullanılarak böcek sınıflandırması ve böcek tespiti yapılmıştır. Bu çalışmada dokuz böcek sınıfına sahip Wang veri seti ve 24 sınıfa sahip Xie veri seti kullanılmıştır. Wang veri seti toplam 225 görüntü içerir, bu da sınıf başına 25 böcek görüntüsü olduğu anlamına gelir ve %70'e-30 eğitim-test oranına bölünmüştür. Wang veri setinde eğitim seti 162 böcek görüntüsü, test seti ise 63 böcek görüntüsü içermektedir. Xie veri seti, eğitim setinde 785 böcek görüntüsü ve her sınıfın yaklaşık 60 böcek görüntüsüne sahip olduğu test setinde 612 böcek görüntüsü içerir. Makine öğrenmesi algoritmaları ile görüntü işleme tekniğinden elde edilen şekil öznitelikleri kullanılarak yapılan sınıflandırma ANN, SVM, KNN ve Naive Bayes'i içermektedir. CNN modelleri, sınıflandırma doğruluğunu her bir teknikle karşılaştırmak için böcek sınıflandırmasında da kullanılmıştır. Hem 1359 böcek görüntüsü için Wang veri kümesine hem de 6892 böcek görüntüsü için Xie veri kümesine uygulanan dokuz katlı çapraz doğrulama, böcek sınıflandırması için geliştirilmiş bir model elde etmek için artırılmış eğitim karısına testi görüntülerini içerir. Rastgele arama parametresi ayarlama yöntemi kullanılarak böceklerin sınıflandırılması için kullanılan parametreler: YSA sınıflandırıcısında, giriş, gizli1, gizli2 ve çıkış katmanındaki nöron sayısı Wang veri seti için 9,150,60 ve 9 ve Xie veri seti için 9,150,60 ve 24 şeklindedir. Giriş ve gizli katmanlarda uygulanan aktivasyon fonksiyonu sigmoid, çıkış katmanında ise softmax; Stokastik gradyan iniş optimize edici uygulanmış olup ve geri yayılım eğitim algoritması, 0.01 öğrenme

oraniyla gerçekleştirılmıştır. SVM sınıflandırıcı, bir radyal temel işlev (RBF) çekirdeği kullanmaktadır. KNN'de 10 olarak seçilen komşu sayısı ve öklid uzaklık metriği uygulanmaktadır. Gauss Naive Bayes algoritması, minimum eğitim süresi ile sınıflandırma sonuçları oluşturmak için çalışmaya göre uyarlanmıştır. CNN modeli, parti büyülüüğü 64, epoch sayısı 50 ve öğrenme oranı 0.001 ile eğitilmiştir.

## KAYNAKÇA

- [1] Cambron, N.C., Cad System For Lung Nodule Analysis, B.S., University Of Louisville, Yüksek Lisans Tezi, 2011.
- [2] Ulaş Alperen Coşkun , Ayşe Demirhan, Farklı Çiçek Türlerini Derin Öğrenme Yöntemi İle Tanıma Recognizing The Different Flower Species By Deep Learning
- [3] "Internet: Tiobe (Programlama Topluluğu Endeksi)", <Https://Www.Tiobe.Com/Tiobe-Index/> (2022).
- [4] Şehirli, E., "A Fully Automated Application For Analysis And Quantification Of Dna Damage On Comet Assay Images Ph . D . Thesis Computer Engineering", Karabük Üniversitesi, (2018).
- [5] Internet: Numpy Developers, "Numpy", <Https://Numpy.Org/> (2022).
- [6] Chityala, R. And Pudipeddi, S., "Image Processing And Acquisition Using Python", Image Processing And Acquisition Using Python, 1–351 (2014).
- [7] Internet: Clark, A., "Python Imaging Library", <Https://Pillow.Readthedocs.Io/En/Stable/Handbook/Overview.Html> 2022).
- [8] Internet: Matplotlib Development Team, "Matplotlib", <Https://Matplotlib.Org/> (2022).
- [9] Salih Büyüner, Kemik Kırıklarının Görüntü İşleme Yöntemleri İle Tam Otomatik Tespit Ve Yapay Zeka Algoritmaları İle Sınıflandırılması,2022
- [10] Harun Pirim, Yapay Zeka,2006
- [11] Krs. Mohri, Mehryar / Rostamizadeh, Afshin / Talwalkar, Ahmeet, Foundations Of Machine Learning, Second Edition, The Mit Press, Abd, 2018, S. 1.
- [12] Kwang Gi Kim; “Deep Learning”; Phd, Biomedical Engineering Branch Division Of Precision Medicine And Cancer Informatics, National Cancer Center, Goyang, Korea, 2016
- [13] Gül Gündüz, İsmail Hakkı Cedimoğlu; “Derin Öğrenme Algoritmalarını Kullanarak Görüntüden Cinsiyet Tahmini”, Sakarya University Journal Of Computer And Information Sciences Vol. 2, No. 1, April 2019
- [14] Sedat Metlek, Kıyas Kayaalp, Derin Öğrenme Yöntemleri İle Arıların Sağlık Durumunun Tespit Edilmesi, Mart 2021

- [15] Mustafa Melih Yılmaz, Makine Öğrenimi Nedir Ve Veri Seti Nasıl Eğitilir?, Temmuz 2022
- [16] Kadir Sabancı, Cevat Aydin, Muhammed Fahri Ünlüerşen, Görüntü İşleme ve Yapay Sinir Ağları Yardımıyla Patates Sınıflandırma Parametrelerinin Belirlenmesi, 2012
- [17] Martineau, M.; Conte, D.; Raveaux, R.; Arnault, I.; Munier, D.; Venturini, G. A Survey On Image-Based Insect Classification. *Pattern Recognit.* 2017, *65*, 273–284.
- [18] Lehmann, J.R.K.; Nieberding, F.; Prinz, T.; Knoth, C. Analysis Of Unmanned Aerial System-Based Cir Images In Forestry—A New Perspective To Monitor Pest Infestation Levels. *Forests* 2015, *6*, 594–612.